

Series de Tiempo para Finanzas

Compendio: ARIMA, SARIMA, SARIMAX, Familia GARCH y Laboratorio de Código

Mauricio Olivares

Profesor: Dr. César Galindo

Universidad Panamericana

Verano 2026

Índice

I	Notebook de Análisis: Código Documentado	3
1.	Carga y Exploración de Datos (California Housing)	3
1.1.	Marco teórico	3
1.2.	Código	3
2.	Simulación de un Proceso AR(1) Estacionario	3
2.1.	Marco teórico	3
2.2.	Código	3
2.3.	Conclusiones	4
3.	Descarga y Visualización de Datos Financieros (AMZN)	4
3.1.	Marco teórico	4
3.2.	Código	4
4.	Simulación y Análisis de Caminata Aleatoria	5
4.1.	Marco teórico	5
4.2.	Código	5
4.3.	Conclusiones	6
5.	Simulación ARIMA y Análisis de Residuos	6
5.1.	Marco teórico	6
5.2.	Código: ajuste y diagnóstico	6
5.3.	Código: predicción	7

6. Análisis con Prophet (Meta)	7
6.1. Marco teórico	7
6.2. Código	8
7. Selección de Orden $AR(p)$: Criterios AIC y BIC	8
7.1. Marco teórico	8
7.2. Código	9
7.3. Conclusiones	10
8. Generación y Análisis de Serie $ARIMA(p, d, q)$	10
8.1. Marco teórico	10
8.2. Código	10
9. Conceptos SARIMA y Dataset AirPassengers	10
9.1. Marco teórico	10
9.2. Código	11
9.3. Conclusiones	11
II Tarea: $ARIMA$, $SARIMA$ y Pronóstico	11
10. Procesos Estacionarios y Fundamentos	12
11. Modelos $ARIMA(p, d, q)$	12
12. Modelos $SARIMA$	13
III Soluciones: $SARIMAX$ y Familia $GARCH$	13
13. Parte A — Ejercicios Analíticos	13
13.1. Identificación $SARIMAX$ con variable exógena macro	13
13.2. Prueba $ARCH$ y motivación del $GARCH$	14
13.3. Estimación e interpretación del $GARCH(1, 1)$	14
13.4. $GJR-GARCH$ y efecto apalancamiento	14
13.5. $EGARCH$: logaritmo de la varianza y asimetría	14
13.6. $GARCH-in-Mean$	14
13.7. Validación $ARIMA-GARCH$ (MXN/USD)	14
13.8. VaR dinámico con $GARCH$	15
13.9. $SARIMAX$ multivariable para WTI	15
13.10. Selección y pronóstico de volatilidad	15
14. Parte B — Preguntas Estilo CFA Level III	15
Bibliografía	16

Parte I

Notebook de Análisis: Código Documentado

1. Carga y Exploración de Datos (California Housing)

1.1. Marco teórico

Aunque el dataset `california_housing_train.csv` no es una serie de tiempo, su carga ilustra el flujo de trabajo estándar con `pandas`: leer datos → inspeccionar estructura → explorar estadísticas descriptivas.

1.2. Código

```
1 import pandas as pd
2
3 ventas = pd.read_csv("california_housing_train.csv")
4 ventas.head(21)
```

Listing 1: Carga del dataset California Housing

2. Simulación de un Proceso AR(1) Estacionario

2.1. Marco teórico

Un proceso **AR(1)** se define como:

$$X_t = c + \phi X_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, \sigma^2) \quad (1)$$

Para que sea **estacionario** se requiere $|\phi| < 1$. En ese caso:

$$E[X_t] = \frac{c}{1 - \phi} \quad (2)$$

$$\text{Var}(X_t) = \frac{\sigma^2}{1 - \phi^2} \quad (3)$$

$$\rho(k) = \phi^k \quad k \geq 0 \quad (4)$$

2.2. Código

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 n_points      = 500
5 phi           = 0.7
6 c             = 0
7 sigma_epsilon = 1.0
8
9 np.random.seed(42)
10 epsilon      = np.random.normal(0, sigma_epsilon, n_points)
11 time_series   = np.zeros(n_points)
12 time_series[0] = epsilon[0]
13 for t in range(1, n_points):
14     time_series[t] = c + phi * time_series[t-1] + epsilon[t]
15
16 plt.figure(figsize=(14, 5))
17 plt.plot(time_series, color='steelblue', lw=0.8)
18 plt.title(f'Proceso AR(1) simulado (phi={phi})', fontsize=13)
19 plt.xlabel('Tiempo'); plt.ylabel('X_t')
20 plt.grid(True, ls='--', alpha=0.5)
21 plt.tight_layout(); plt.show()
22
23 print(f"Media muestral      : {np.mean(time_series):.4f}")
24 print(f"Varianza muestral: {np.var(time_series):.4f}")
25 print(f"Var. teorica          : {sigma_epsilon**2/(1-phi**2):.4f}")

```

Listing 2: Simulación AR(1) estacionario

2.3. Conclusiones

La media muestral converge a $c/(1 - \phi) = 0$ y la varianza a $\sigma^2/(1 - \phi^2) \approx 1.96$. La serie oscila alrededor de cero sin tendencia, confirmando la estacionariedad.

3. Descarga y Visualización de Datos Financieros (AMZN)

3.1. Marco teórico

Los precios en nivel son **no estacionarios** (raíz unitaria), pero los log-retornos $r_t = \ln(P_t/P_{t-1})$ sí lo son aproximadamente.

3.2. Código

```

1 import yfinance as yf
2 import plotly.express as px
3

```

```

4 amzn = yf.download("AMZN", end="2026-01-01",
    progress=False)
5 precios_amzn = amzn["Close"]
6
7 fig = px.line(
8     precios_amzn,
9     x=precios_amzn.index,
10    y='AMZN',
11    title='Precios de Cierre de AMZN',
12    labels={'index': 'Fecha', 'AMZN': 'Precio de Cierre (USD)'},
13    template='plotly_white'
14 )
15 fig.show()

```

Listing 3: Descarga de precios AMZN con yfinance

4. Simulación y Análisis de Caminata Aleatoria

4.1. Marco teórico

Una **caminata aleatoria**: $X_t = X_{t-1} + Z_t$, con $\text{Var}(X_t) = t\sigma^2 \rightarrow \infty$. La primera diferencia $\Delta X_t = Z_t$ sí es estacionaria.

Prueba **ADF**: H_0 = raíz unitaria. Si $\text{ADF} > -2,89$ no se rechaza H_0 ; se diferencia la serie.

4.2. Código

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3 from statsmodels.tsa.stattools import adfuller, kpss
4
5 np.random.seed(42)
6 n = 300
7 Z = np.random.normal(0, 1, n)
8 X = np.cumsum(Z)
9
10 adf_result = adfuller(X, autolag='AIC')
11 print(f"ADF (nivel): {adf_result[0]:.4f}  p={adf_result[1]:.4f}")
12
13 dX = np.diff(X)
14 adf_diff = adfuller(dX, autolag='AIC')
15 print(f"ADF (diff) : {adf_diff[0]:.4f}  p={adf_diff[1]:.4f}")
16
17 fig, axes = plt.subplots(2, 1, figsize=(13, 8))
18 axes[0].plot(X, color='#e74c3c', lw=1.2);
    axes[0].set_title('Nivel $X_t$')

```

```

19 axes[1].plot(dX, color='steelblue', lw=1);
    axes[1].set_title('Diferencia $\Delta X_t$')
20 for ax in axes:
21     ax.grid(True, ls='--', alpha=0.5)
22 plt.tight_layout(); plt.show()

```

Listing 4: Caminata aleatoria y pruebas ADF/KPSS

4.3. Conclusiones

En nivel: ADF no rechaza raíz unitaria. En primera diferencia: ADF rechaza $H_0 \Rightarrow$ modelos ARIMA con $d = 1$ son apropiados.

5. Simulación ARIMA y Análisis de Residuos

5.1. Marco teórico

Un proceso $\text{ARIMA}(p, d, q)$:

$$\Phi_p(B)(1 - B)^d Y_t = \Theta_q(B) \varepsilon_t \quad (5)$$

Los residuos de un modelo bien especificado deben ser **ruido blanco**: media cero, varianza constante y sin autocorrelación (verificado con ACF/PACF, histograma y Q-Q plot).

5.2. Código: ajuste y diagnóstico

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3 from statsmodels.tsa.ar_model import AutoReg
4 from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
5 import statsmodels.api as sm
6
7 np.random.seed(42)
8 n_points = 500; phi = 0.7
9 epsilon = np.random.normal(0, 1, n_points)
10 time_series = np.zeros(n_points)
11 for t in range(1, n_points):
12     time_series[t] = phi * time_series[t-1] + epsilon[t]
13
14 model = AutoReg(time_series, lags=1).fit()
15 residuals = model.resid
16 print(f"phi estimado: {model.params[1]:.4f}")
17 print(f"Media resid : {np.mean(residuals):.4f}")
18 print(f"Std resid   : {np.std(residuals):.4f}")
19
20 fig, axes = plt.subplots(1, 3, figsize=(18, 5))

```

```

21 axes[0].plot(residuals, color='steelblue', lw=0.7)
22 axes[0].axhline(0, color='red', ls='--')
23 axes[0].set_title('Residuales vs. Tiempo')
24 axes[1].hist(residuals, bins=30, color='steelblue',
    edgecolor='white')
25 axes[1].set_title('Histograma de Residuales')
26 sm.qqplot(residuals, line='s', ax=axes[2])
27 axes[2].set_title('Q-Q Plot')
28 plt.tight_layout(); plt.show()
29
30 fig2, axes2 = plt.subplots(1, 2, figsize=(14, 5))
31 plot_acf(residuals, ax=axes2[0], lags=40);
    axes2[0].set_title('ACF Residuales')
32 plot_pacf(residuals, ax=axes2[1], lags=40);
    axes2[1].set_title('PACF Residuales')
33 plt.tight_layout(); plt.show()

```

Listing 5: AR(1): ajuste y diagnóstico de residuos

5.3. Código: predicción

```

1 forecast_steps = 50
2 forecast = model.predict(
3     start=len(time_series),
4     end=len(time_series) + forecast_steps - 1
5 )
6
7 plt.figure(figsize=(14, 5))
8 plt.plot(range(len(time_series)), time_series,
9     label='Serie original', color='steelblue', lw=0.8)
10 plt.plot(range(len(time_series),
11     len(time_series)+forecast_steps),
12     forecast, label='Pronostico', color='red', ls='--',
13     lw=1.5)
14 plt.title('Pronostico AR(1)')
15 plt.xlabel('Tiempo'); plt.ylabel('$X_t$')
16 plt.legend(); plt.grid(True, ls='--', alpha=0.5)
17 plt.tight_layout(); plt.show()

```

Listing 6: Pronóstico con modelo AR(1)

6. Análisis con Prophet (Meta)

6.1. Marco teórico

Prophet descompone la serie en componentes aditivos:

$$y(t) = g(t) + s(t) + h(t) + \varepsilon_t \quad (6)$$

Característica	ARIMA	Prophet
Identificación	ACF/PACF (p, d, q)	Automática
Estacionalidad	SARIMA con s fijo	Múltiple y flexible
Tendencia	Diferenciación	Lineal o logística
Valores atípicos	Sensible	Robusto

Cuadro 1: Comparación ARIMA vs. Prophet.

6.2. Código

```

1 # !pip install prophet
2 import pandas as pd
3 from prophet import Prophet
4 import matplotlib.pyplot as plt
5
6 data_url = ('https://raw.githubusercontent.com/facebook/prophet/'
7            'main/examples/example_wp_log_peyton_manning.csv')
8 df_prophet = pd.read_csv(data_url)
9
10 model_prophet = Prophet()
11 model_prophet.fit(df_prophet)
12
13 future = model_prophet.make_future_dataframe(periods=365)
14 forecast = model_prophet.predict(future)
15
16 fig1 = model_prophet.plot(forecast)
17 plt.title('Pronostico con Prophet'); plt.show()
18
19 fig2 = model_prophet.plot_components(forecast)
20 plt.show()

```

Listing 7: Ajuste y pronóstico con Prophet

7. Selección de Orden $AR(p)$: Criterios AIC y BIC

7.1. Marco teórico

$$AIC = -2 \ln \hat{L} + 2k \quad (7)$$

$$BIC = -2 \ln \hat{L} + k \ln(n) \quad (8)$$

Se elige el modelo con el **menor** criterio. BIC penaliza más la complejidad ($\ln n > 2$ para $n > 7$).

7.2. Código

```

1 import numpy as np
2 import pandas as pd
3 import plotly.graph_objects as go
4 from statsmodels.tsa.ar_model import AutoReg
5
6 np.random.seed(42)
7 n_points = 500; phi = 0.7
8 epsilon = np.random.normal(0, 1, n_points)
9 time_series = np.zeros(n_points)
10 for t in range(1, n_points):
11     time_series[t] = phi * time_series[t-1] + epsilon[t]
12
13 results = []
14 for p in range(1, 21):
15     try:
16         res = AutoReg(time_series, lags=p).fit()
17         results.append({'Order': p, 'AIC': res.aic, 'BIC':
18             res.bic})
19     except Exception:
20         pass
21
22 ic_df = pd.DataFrame(results)
23 print(f"Orden optimo AIC:
24     {ic_df.loc[ic_df['AIC'].idxmin(), 'Order']}")
25 print(f"Orden optimo BIC:
26     {ic_df.loc[ic_df['BIC'].idxmin(), 'Order']}")
27
28 fig = go.Figure([
29     go.Scatter(x=ic_df['Order'], y=ic_df['AIC'],
30         mode='lines+markers', name='AIC',
31         line=dict(color='blue')),
32     go.Scatter(x=ic_df['Order'], y=ic_df['BIC'],
33         mode='lines+markers', name='BIC',
34         line=dict(color='red'))
35 ])
36 fig.update_layout(title='AIC y BIC para Modelos AR(p)',
37     xaxis_title='Orden p',
38     yaxis_title='Criterio de Informacion',
39     template='plotly_white')
40 fig.show()

```

Listing 8: Selección de orden AR por AIC/BIC

7.3. Conclusiones

Para la serie AR(1) con $\phi = 0,7$, tanto AIC como BIC seleccionan $p = 1$, confirmando que los criterios recuperan el proceso verdadero. Para $p > 1$ los criterios crecen: los rezagos adicionales son sobreajuste.

8. Generación y Análisis de Serie ARIMA(p, d, q)

8.1. Marco teórico

ARIMA(p, d, q) integra tres componentes: p (rezagos AR, identificado con PACF), d (diferencias para estacionariedad, prueba ADF), q (términos MA, identificado con ACF).

8.2. Código

```

1 import numpy as np
2 from statsmodels.tsa.arima.model import ARIMA
3 import matplotlib.pyplot as plt
4
5 np.random.seed(42)
6 n = 500; phi_true = 0.7
7 eps = np.random.normal(0, 1, n)
8 y = np.zeros(n)
9 for t in range(1, n):
10     y[t] = phi_true * y[t-1] + eps[t]
11
12 model_arima = ARIMA(y, order=(1, 0, 0)).fit()
13 print(model_arima.summary())
14
15 plt.figure(figsize=(13, 5))
16 plt.plot(y, color='steelblue', lw=0.8, label='Serie simulada')
17 plt.title('Serie ARIMA(1,0,0) simulada')
18 plt.xlabel('Tiempo'); plt.ylabel('$Y_t$')
19 plt.legend(); plt.grid(True, ls='--', alpha=0.5)
20 plt.tight_layout(); plt.show()

```

Listing 9: Simulación y ajuste ARIMA(1,0,0)

9. Conceptos SARIMA y Dataset AirPassengers

9.1. Marco teórico

SARIMA(p, d, q)(P, D, Q) $_s$:

$$\Phi_P(B^s) \Phi_p(B) (1 - B^s)^D (1 - B)^d Y_t = \Theta_Q(B^s) \Theta_q(B) \varepsilon_t \quad (9)$$

Guía de identificación: d (ADF regular), D (ACF en rezagos $s, 2s, \dots$), p (PACF diferenciada), q (ACF diferenciada), P, Q (PACF/ACF en múltiplos de s).

Nota: la ACF de un AR puro no informa sobre el orden; usar la PACF.

9.2. Código

```

1 import pandas as pd
2 import numpy as np
3 import statsmodels.api as sm
4 import matplotlib.pyplot as plt
5 from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
6
7 air_data = sm.datasets.get_rdataset('AirPassengers', 'datasets')
8 air_df = air_data.data.copy()
9 air_df.index = pd.period_range(start='1949-01',
10                                periods=len(air_df), freq='M')
11
12 plt.figure(figsize=(13, 5))
13 plt.plot(air_df.index.to_timestamp(), air_df['value'],
14          color='steelblue', lw=1.2)
15 plt.title('AirPassengers: Pasajeros Aereos Internacionales
16           (1949-1960)')
17 plt.xlabel('Fecha'); plt.ylabel('Miles de pasajeros')
18 plt.grid(True, ls='--', alpha=0.5)
19 plt.tight_layout(); plt.show()
20
21 log_air = np.log(air_df['value'])
22
23 fig, axes = plt.subplots(1, 2, figsize=(14, 5))
24 plot_acf(log_air, ax=axes[0], lags=40)
25 axes[0].set_title('ACF log(Pasajeros)')
26 plot_pacf(log_air, ax=axes[1], lags=40)
27 axes[1].set_title('PACF log(Pasajeros)')
28 plt.tight_layout(); plt.show()

```

Listing 10: Dataset AirPassengers: carga y exploración

9.3. Conclusiones

La serie muestra tendencia creciente y estacionalidad multiplicativa ($s = 12$). La log-transformación convierte la estacionalidad en aditiva. Se requiere $d = 1$ y $D = 1$: modelo de Airline SARIMA(0, 1, 1)(0, 1, 1)₁₂.

Parte II

Tarea: ARIMA, SARIMA y Pronóstico

10. Procesos Estacionarios y Fundamentos

Ejercicio 1.1 — Estacionariedad, ACF y PACF

Definición 10.1 (Estacionariedad débil). $\{Y_t\}$ es débilmente estacionario si $E[Y_t] = \mu$ para todo t y $\text{Cov}(Y_t, Y_{t-k}) = \gamma(k)$ depende sólo de k .

Definición 10.2 (Estacionariedad estricta). La distribución conjunta de $(Y_{t_1}, \dots, Y_{t_m})$ coincide con la de $(Y_{t_1+h}, \dots, Y_{t_m+h})$ para todo h .

Propiedades ACF: $|\rho(k)| \leq 1$ y $\rho(k) = \rho(-k)$.

AR(1): para $Y_t = 0,6 Y_{t-1} + \varepsilon_t$:

$$\text{Var}(Y_t) = \frac{\sigma^2}{1 - 0,36}, \quad \rho(k) = 0,6^k$$

Ejercicio 1.2 — Procesos AR, MA y ARMA

AR(2): $Y_t = 1,2 Y_{t-1} - 0,32 Y_{t-2} + \varepsilon_t$. Raíces de $\Phi(z) = 1 - 1,2z + 0,32z^2$: $z_1 = 1,25$, $z_2 = 2,5$. Fuera del círculo unitario $\Rightarrow$ **estacionario**.

Invertibilidad MA(q): raíces de $\Theta(z)$ fuera del círculo unitario.

Ejercicio 1.3 — Raíces Unitarias

Caminata aleatoria: $\text{Var}(Y_t) = t\sigma^2 \Rightarrow$ no estacionaria. Primera diferencia: $\Delta Y_t = \varepsilon_t \Rightarrow$ estacionaria.

11. Modelos ARIMA(p, d, q)

Ejercicio 2.1 — Procedimiento Box-Jenkins

(i) Identificación (ACF/PACF), (ii) Estimación (MV o MCO), (iii) Diagnóstico (residuos como ruido blanco).

Ejercicio 2.2 — ARIMA(1, 1, 1) para log-precios

$(1 - \phi_1 B) r_t = (1 + \theta_1 B) \varepsilon_t$, con $r_t = \Delta y_t$.

Con $\hat{\phi}_1 = 0,15$, $\hat{\theta}_1 = -0,08$: $\hat{r}_{T+1|T} = \hat{\phi}_1 r_T + \hat{\theta}_1 \varepsilon_T$.

Ejercicio 2.3 — Pronóstico horizonte múltiple

ARIMA(2, 1, 0), $W_t = \Delta Y_t$: $W_t = 0,5 W_{t-1} - 0,2 W_{t-2} + \varepsilon_t$.

12. Modelos SARIMA**Ejercicio 3.1 — Estructura estacional**

SARIMA(1, 1, 1)(1, 1, 1)₁₂:

$$\Phi_1(B^{12}) \phi_1(B) (1 - B)(1 - B^{12}) Y_t = \Theta_1(B^{12}) \theta_1(B) \varepsilon_t$$

Ejercicio 3.2 — Modelo de Airline

$$(1 - B)(1 - B^{12}) V_t = (1 + \theta_1 B)(1 + \Theta_1 B^{12}) \varepsilon_t.$$

Lado izquierdo: $V_t - V_{t-1} - V_{t-12} + V_{t-13}$.

Ejercicio 3.3 — Tasas de interés (CETES)

SARIMA(p, d, q)(P, D, Q)₁₃ por ciclo trimestral de 13 semanas.

Parte III**Soluciones: SARIMAX y Familia GARCH****13. Parte A — Ejercicios Analíticos****13.1. Identificación SARIMAX con variable exógena macro**

SARIMAX(1, 1, 1)(1, 1, 0)₁₂, $n = 156$, $x_t =$ rendimiento T-Note 10Y.

(a) Ecuación completa:

$$(1 - \Phi_1 B^{12})(1 - \phi_1 B)(1 - B)(1 - B^{12}) y_t = \beta x_t + (1 + \theta_1 B) \varepsilon_t$$

(b) ADF = $-1,42 > -2,89 \Rightarrow$ raíz unitaria; $d = 1$, $D = 1$.

(c) $\hat{\beta} = -0,87$: aumento de 1 p.p. en T-Note $\Rightarrow$ caída relativa $\approx 58\%$ en precio del bono.

(d) $t = -0,87/0,12 = -7,25$, $IC_{95\%} = [-1,105, -0,635]$. Altamente significativo ($p < 0,01$).

13.2. Prueba ARCH y motivación del GARCH

LM-ARCH(5) = 47,83 ($p \approx 4 \times 10^{-6}$). Se rechaza H_0 (varianza condicional constante) $\Rightarrow$ GARCH apropiado.

Si $r_t \sim \text{ARCH}(1)$:

$$r_t^2 = \omega + \alpha r_{t-1}^2 + u_t \quad (\text{AR}(1) \text{ en } r_t^2)$$

13.3. Estimación e interpretación del GARCH(1, 1)

$$\hat{\omega} = 0,0285, \hat{\alpha} = 0,083, \hat{\beta} = 0,901.$$

$$\hat{\alpha} + \hat{\beta} = 0,984 < 1 \quad \checkmark$$

$$\bar{\sigma}^2 = \frac{0,0285}{0,016} = 1,781 \%^2/\text{día}, \quad \bar{\sigma}_{\text{anual}} \approx 21,19 \%$$

$$\text{Con } \varepsilon_t = -2,5 \%, \hat{\sigma}_t = 1,2 \%: \hat{\sigma}_{t+1}^2 = 1,8447 \%^2 \Rightarrow \hat{\sigma}_{t+1} = 1,358 \%.$$

$$\text{Vida media: } h^* = \ln 0,5 / \ln 0,984 \approx 43 \text{ días.}$$

13.4. GJR-GARCH y efecto apalancamiento

$$\hat{\lambda}/\hat{\alpha} = 0,078/0,042 = 1,857 \Rightarrow +186 \%.$$

$$\text{Estacionariedad: } \hat{\alpha} + \frac{1}{2}\hat{\lambda} + \hat{\beta} = 0,993 < 1 \quad \checkmark$$

13.5. EGARCH: logaritmo de la varianza y asimetría

$$\hat{\gamma} = -0,063 < 0 \text{ confirma efecto apalancamiento.}$$

$$g(-2) - g(+2) = 0,252 \Rightarrow \sigma_t^2 \times e^{0,252} \approx +28,7 \% \text{ extra ante choque negativo.}$$

13.6. GARCH-in-Mean

$$\hat{\delta} = 0,38: \text{prima de riesgo por unidad de volatilidad.}$$

$$\text{Con } \hat{\sigma}_t = 0,08: E_t[r_{t+1}] = 0,012 + 0,38(0,08) = 4,24 \% \text{ trimestral } (\approx 18 \% \text{ anual}).$$

13.7. Validación ARIMA-GARCH (MXN/USD)

Protocolo de 5 pasos:

1. LB($\hat{z}_t$) $p = 0,36 > 0,05$: sin autocorrelación en media.
2. LB($\hat{z}_t^2$) $p = 0,51 > 0,05$: GARCH absorbió heterocedasticidad.
3. JB $p = 0$: normalidad rechazada $\Rightarrow$ distribución t_ν .
4. Negative-Size-Bias $p = 0,003$: asimetría $\Rightarrow$ GJR o EGARCH.

5. Confirmar $\alpha + \beta < 1$ y calcular vida media.

13.8. VaR dinámico con GARCH

$V = \$10,000,000$, $\hat{\sigma}_t = 1,84\%$, $\nu = 6,2$.

$$\text{VaR}_{95\%} = \$353,100 \quad \text{VaR}_{99\%} = \$573,800$$

Backtest de Kupiec:

$$\text{LR}_{uc} = -2 \ln \left[\frac{(1 - \alpha)^{T-X} \alpha^X}{(1 - \hat{\pi})^{T-X} \hat{\pi}^X} \right] \sim \chi_1^2$$

13.9. SARIMAX multivariable para WTI

$\hat{\beta}_1 = -0,412$ (REER), $\hat{\beta}_2 = +0,587$ (PMI).

$$\Delta \log \hat{P}_{t+3} = 0,587 \times 1,5 = 0,8805 \Rightarrow \hat{P}_{t+3} \approx P_t \cdot e^{0,8805}.$$

13.10. Selección y pronóstico de volatilidad

Por AIC: GJR-GARCH- t (3224.3). Por BIC: GARCH(1,1)- t (3249.6).

h	$(\alpha + \beta)^{h-1}$	σ_{t+h}^2	σ_{t+h}
1	1.000	0.002500	0.05000
2	0.963	0.002474	0.04974
3	0.927	0.002449	0.04949
4	0.893	0.002425	0.04924
5	0.860	0.002402	0.04901

Cuadro 2: Pronóstico recursivo de volatilidad a 5 días.

14. Parte B — Preguntas Estilo CFA Level III

P11	P12	P13	P14	P15	P16	P17	P18	P19	P20
B	B	B	B	B	B	A	B	A	C

Cuadro 3: Respuestas Parte B.

Razonamientos clave:

- **P11 (B):** $\text{ACF}(r_t^2)$ significativa es la firma del efecto ARCH.
- **P12 (B):** $\alpha + \beta = 0,99 \Rightarrow$ vida media ≈ 69 días.
- **P13 (B):** EGARCH modela $\log \sigma_t^2$; sin restricciones de signo.

- **P17 (A):** $\hat{\delta} > 0 \Rightarrow$ prima de riesgo positiva (Merton 1973).
- **P19 (A):** Regla $\sqrt{10}$ supone i.i.d.; bajo GARCH hay que iterar.
- **P20 (C):** JB rechaza normalidad $\Rightarrow$ QML o verosimilitud t .

Bibliografía

1. Box, G.E.P., Jenkins, G.M. & Reinsel, G.C. (2015). *Time Series Analysis*, 5th ed. Wiley.
2. Engle, R.F. (1982). Autoregressive conditional heteroscedasticity. *Econometrica*, 50(4), 987–1007.
3. Bollerslev, T. (1986). Generalized ARCH. *Journal of Econometrics*, 31(3), 307–327.
4. Glosten, L., Jagannathan, R. & Runkle, D. (1993). On the relation between expected value and volatility. *Journal of Finance*, 48(5), 1779–1801.
5. Nelson, D.B. (1991). Conditional heteroskedasticity in asset returns. *Econometrica*, 59(2), 347–370.
6. Taylor, S.J. & Letham, B. (2018). Forecasting at scale. *The American Statistician*, 72(1), 37–45.
7. Kupiec, P. (1995). Techniques for verifying accuracy of risk models. *Journal of Derivatives*, 3(2), 73–84.
8. Merton, R.C. (1973). An intertemporal CAPM. *Econometrica*, 41(5), 867–887.